

## ESTATÍSTICA COMPUTACIONAL E SIMULAÇÃO

*Folha prática 2: Métodos de Monte Carlo em Inferência Estatística e*

*Métodos de Reamostragem - bootstrap e jackknife*

*Ano letivo 2021/22*

1. Determine estimativas de  $p = P(X > 2)$ , com  $X \sim C(0, 1)$ , i.e.,

$$f(x) = \frac{1}{\pi(1+x^2)}, -\infty < x < \infty,$$

usando

- (a) a distribuição de Cauchy standard
  - (b) a distribuição Uniforme definida em  $(0, 2)$
  - (c) Sabe-se que  $p = 0.14758$ . Compare os resultados anteriormente obtidos e as respectivas variâncias
2. Pretende-se calcular o valor do integral

$$I = \int_0^\infty \log(x) x^5 e^{-3x} dx.$$

Usando o método de integração de Monte Carlo, obtenha estimativas fazendo simulações de

- (a) distribuição  $X \sim Exp(3)$
  - (b) distribuição  $X \sim Ga(6, 3)$
  - (c) use ainda o método das réplicas pra estimar  $I$  com  $X \sim Ga(6, 3)$
  - (d) Sabe-se que  $I = 0.1000009$ . Compare os resultados anteriormente obtidos com o exato e com o valor estimado para o integral (e respetivo erro) no caso de usar o método das réplicas.
3. Pretende-se estimar o seguinte integral

$$\int_0^1 \frac{e^{-x}}{1+x^2} dx$$

usando a técnica da amostragem de importância. Considere as seguintes funções como candidatas a funções de importância:

$$f_1(x) = 1, 0 < x < 1, \quad f_2(x) = e^{-x}, 0 < x < \infty, \quad f_3(x) = \frac{1}{\pi(1+x^2)}, -\infty < x < \infty,$$

$$f_4(x) = \frac{e^{-x}}{1-e^{-1}}, 0 < x < 1, \quad f_5(x) = 4 \frac{1}{\pi(1+x^2)}, 0 < x < 1.$$

Determine os erros associados e analise quais as que mais reduzem a variância da estimativa do integral.

4. Seja  $X \sim N(1, \sigma^2)$ . Sabe-se

$$\left] \frac{(n-1)S_c^2}{\chi_{1-\alpha/2, n-1}^2}, \frac{(n-1)S_c^2}{\chi_{\alpha/2, n-1}^2} \right[$$

é um intervalo de confiança para  $\sigma^2$  a  $100(1-\alpha)\%$ . Usando o método de Monte Carlo determine um intervalo de confiança para  $\sigma^2$ .

5. Considere uma série temporal definida por  $X_t = aX_{t-1} + Y_t$ , onde  $Y \sim N(0, \sigma^2)$ . O estimador dos mínimos quadrados de  $a$  é dado por

$$T = \frac{\sum_{t=2}^n X_t X_{t-1}}{\sum_{t=2}^n X_{t-1}^2}.$$

Supondo o modelo com parâmetros  $a = 0.3$  e  $\sigma^2 = 1$ , uma amostra com 100 observações e usando o método das réplicas (use 1000)

- (a) determine uma estimativa do parâmetro  $a$ ;
  - (b) calcule o desvio padrão, erro quadrático médio e viés associado à estimativa obtida; obtenha o boxplot da amostra dos envezamentos.
  - (c) determine um intervalo de confiança para  $a$ .
6. Suponha que se pretende
- (a) testar  $H_0 : \sigma^2 = 4$  vs  $H_1 : \sigma^2 > 4$ , ao nível de significância  $\alpha = 0.05$ . Usando 100000 réplicas, determine estimativas do nível de significância do teste, considerando amostras de dimensão 100 de populações normais de valor médio unitário, tomando  $\sigma^2 = 4$ ,  $\sigma^2 = 10$  e  $\sigma^2 = 1$ . Comente os resultados.
  - (b) determinar um intervalo de confiança para  $\sigma^2$ , considerando o método de Monte Carlo e usando dados provenientes de  $N(1, 4)$ .
7. Os dados que se encontram no ficheiro "tabaco.txt" dizem respeito a um estudo feito sobre a relação entre tabaco e cancro de pulmão. Foram estudados 25 grupos ocupacionais. A variável explicativa  $x$  é o número de cigarros fumados por dia por indivíduos do sexo masculino em cada grupo ocupacional. A variável resposta  $y$  é a taxa de mortalidade estandardizada devida a mortes por cancro do pulmão.
- (a) Represente graficamente os dados e obtenha o coeficiente de correlação empírico.
  - (b) Gere 1000 amostras bootstrap dos dados, obtenha o respectivo coeficiente de correlação e calcule uma estimativa do erro padrão do coeficiente de correlação.
8. Considere os dados referentes a duração de erupções da nascente termal (geyser) Old Faithful - disponíveis na livraria MASS do R como "faithful\$eruptions". Pretende-se determinar um intervalo de confiança para o valor médio da população subjacente aos dados. Considerando o estimador  $\bar{X}$ , determine esse intervalo de confiança usando o método de reamostragem de bootstrap.
9. Para uma amostra  $X_1, \dots, X_n$  iid a  $X$ , considere o estimador  $\hat{\theta}_n = \bar{X}$  para o valor médio de  $X$ . Então sabemos que  $se(\hat{\theta}_n) = \sqrt{Var(X)/n}$ . Mostre que
- (a)  $\hat{\theta}^{(j)} = \frac{n\bar{X} - X_j}{n-1}$ .
  - (b)  $\hat{\theta}^{(-)} = \bar{X}$ .
  - (c)  $\hat{se}_{jack}(\hat{\theta}_n) = \sqrt{S_n^2/n}$ , com  $S_n^2 = \frac{1}{n-1} \sum_{j=1}^n (X_j - \bar{X})^2$ .
10. Resolva o exercício 7 usando o método de reamostragem de Jackknife para estimar a correlação e calcule uma estimativa do seu viés.